Исполнитель: Седов М.А.
Гипотеза №6 - Как лучше всего моделировать сезонность?

«Комбинация разных типов признаков улучшает качество прогноза глобальной модели по сравнению с использованием отдельных групп признаков»

Постановка задачи:

1) Отобрать 100 временных рядов с сильно и слабо выраженной сезонностью из датасета M4;

2) Реализовать 4 бейзлайна;

3) Обучить CatBoost с 6 различными наборами признаков;

4) Проанализировать зависимость качества от типа признаков;

5) Сравнить лучшую модель CatBoost с бейзлайнами и сделать выводы.

Описание данных:

Датасет: M4 Monthly frequency

Общий объём: 48 000 временных рядов

Частота: Месячная

Для проверки гипотеза была сделана выборка из 100 рядов. Ряды отбирались по значению автокорреляционной функции (ACF) на сезонном лаге:

-Слабая сезонность (ACF < 0.4): 6 рядов

-Сильная сезонность (ACF ≥ 0.4): 94 ряда

Методология эксперимента:

Разделение: последние 18 наблюдений — тест

Train: 23 147 наблюдений

Test: 1 800 наблюдений (100 рядов × 18 точек)

Метрики:

-MAE;

-RMSE;

-MAPE.

Наборы признаков:

-regular

-seasonal

-fourier

-calendar

-regular + seasonal

-regular + seasonal + fourier + calendar

Описание моделей:

Бейзлайны:

-Naive

-SeasonalNaive

-AutoTheta

-AutoETS

Глобальная модель для основных экспериментов – CatBoost

Результаты:

Метрики базовых моделей:

	MAE	RMSE	MAPE
Naive	447.2859	782.3140	14.8165
SeasonalNaive	443.1410	733.0858	16.0398
AutoTheta	400.6173	724.5381	12.2296
AutoETS	444.0067	766.1434	14.5369

Результаты CatBoost разных наборов признаков:

	MAE	RMSE	MAPE
regular	271.5170	574.3206	6.8167
seasonal	396.9198	641.9074	14.0438
fourier	2295.3964	3147.3111	77.8685
calendar	2386.7535	3307.0671	81.2836
combined_1	242.4850	427.5035	6.8249
combined_2	240.0728	434.0972	6.6698

Выводы:

Результаты экспериментов однозначно подтверждают выдвинутую гипотезу. Наилучшее качество прогноза было достигнуто при использовании модели CatBoost с комбинированным набором признаков. Такая конфигурация признаков дала значение метрики MAPE = 6.67%, что значительно лучше метрик бейзлайнов. Также стоит сказать, что отдельные группы признаков,

такие как фурье или только календарные, показывают очень низкие значения метрик (MAPE = 77% и 81% соответственно) при использовании без лаговых переменных, что свидетельствует о том, что данные признаки дополняют, но не заменяют базовую лаговую структуру модели.

В итоге, можно сделать вывод, что для задачи прогнозирования месячных временных рядов с выраженной сезонностью оптимальной стратегией является использование глобальной модели градиентного бустинга с комбинированным набором признаков, включающим лаги различного типа, гармонические компоненты и календарные переменные.